

웹 콘텐츠 내 악성 지시의 LLM 에이전트 장기 메모리 저장 가능성 분석†

이정환*, 지전일**, 조금환***

*, **, *** 고려대학교 세종캠퍼스 (학부생, 대학원생, 교수)

An Analysis of Long-term Memory Write for Web-Exposed Malicious Instructions in LLM Agents

Jeonghan Lee*, Jeonil Ji**, Geumhwan Cho***

*, **, *** Korea University Sejong Campus (Student, Graduate student, Professor)

요약

LLM 에이전트의 장기 메모리는 획득한 정보를 세션 종료 이후에도 유지하고 후속 작업에서 다시 활용할 수 있게 한다. 그러나 웹 탐색 중 게시물이나 리뷰 등 제3자 콘텐츠에 포함된 악성 지시가 장기 메모리에 저장되면 이후 세션에서 다시 활용되어 지속적인 보안 위협으로 이어질 수 있다. 본 논문에서는 Mem0를 장기 메모리로 사용하는 OpenClaw 환경에서 웹 콘텐츠의 악성 지시가 실제 장기 메모리에 저장되는지를 실험하였다. 평가 과정은 악성 지시 노출, 장기 메모리 기록, 악성 지시 저장의 세 단계로 구분하였다. 악성 지시를 삽입한 웹페이지 30개를 GPT-5.6 Sol, Terra, Luna 기반 에이전트가 탐색하도록 한 결과, 세 모델 모두 악성 지시에 노출되었으나 저장된 사례는 없었다. 반면 사용자가 동일한 지시를 장기 메모리에 저장하도록 직접 요청한 조건에서는 10회 모두 저장되었다. 또한 동일한 요청을 사용자 지시 형식으로 웹페이지에 삽입하고 OpenClaw의 외부 콘텐츠 비신뢰 표식을 제거한 조건에서는 10회 중 3회 저장되었다.

I. 서론


LLM 에이전트는 웹을 탐색해 정보를 수집하고 그 결과를 바탕으로 사용자를 대신해 작업을 수행할 수 있다. 이 과정에서 접하는 댓글, 리뷰, 게시물 등은 제3자가 작성한 외부 콘텐츠이며 사용자의 지시와 함께 모델의 입력 컨텍스트에서 처리될 수 있다[1]. 공격자가 공개 웹 콘텐츠에 악성 지시를 삽입해 이를 처리하는 LLM 에이전트의 행동을 조작하는 공격을 간접 프롬프트 인젝션이라 한다. 공격이 성공하면 사용자 권한을 위임받은 에이전트가 파일 유출과 같이 사용자가 의도하지 않은 행동을 수행할 수 있다. 악성 지시가 장기 메모리에 저장되고 이후 세션에서 검색 및 활용될 경우, 공격자의 추가 개입 없이 공격의 영향이 여러 세

션에 걸쳐 지속될 수 있다[2].

기존 연구는 외부 입력이 장기 메모리에 기록될 가능성을 실험하거나[2] 이미 저장된 악성 지시가 후속 세션에서 재사용되어 사용자가 요청하지 않은 행동을 유발할 수 있음을 보였다[3]. 그러나 기존 실험은 악성 지시가 저장된 상태를 전제하거나 웹 콘텐츠를 에이전트의 입력으로 직접 제공하였다. 따라서 에이전트가 브라우저로 웹페이지를 탐색하는 과정에서 접한 악성 지시가 장기 메모리에 저장되는지는 충분히 검증되지 않았다.

본 논문에서는 Mem0를 연동한 OpenClaw 환경에서 웹 콘텐츠의 악성 지시가 장기 메모리에 유입되는 과정을 노출, 장기 메모리 기록, 악성 지시 저장의 세 단계로 나누어 측정한다 ([그림 1] 참조). GPT-5.6 Sol, Terra, Luna 기반 에이전트를 대상으로 실험한 결과, 기본 설정에서는 세 모델 모두 악성 지시를 처리했으나 해당 지시가 장기 메모리에 저장된 사례는

† 본 연구는 2025년도 교육부의 재원으로 한국연구재단이 지원하는 기초연구사업(No. RS-2025-25411243)과 과학기술정보통신부 및 정보통신기획평가원이 지원하는 SW중심대학사업(No. 2024-0-00036)의 지원을 받아 수행되었음.



[그림 1] 위협 모델과 장기 메모리 기록 과정

없었다. 반면 사용자가 직접 저장을 요청한 조건에서는 10회 모두 저장되었으며, 동일한 요청을 사용자 지시 형식으로 웹페이지에 삽입하고 OpenClaw의 외부 콘텐츠 태그와 경고 문구를 제거한 조건에서는 10회 중 3회 저장되었다.

II. 관련연구

LLM 에이전트의 장기 메모리 오염은 웹페이지와 이메일 등 다양한 외부 입력 경로를 대상으로 연구되어 왔다. Zou[3] 등은 웹페이지에 포함된 악성 지시가 에이전트의 작업 기록에 자동으로 저장되고 후속 세션에서 재사용될 수 있음을 보였으며, Zhang[4] 등은 이메일을 통해 유입된 악성 지시가 사용자가 인지하기 어려운 형태로 장기 메모리에 기록될 수 있음을 확인하였다. Dash[2] 등은 OpenClaw와 HERMES를 대상으로 다양한 외부 입력의 메모리 기록 여부를 평가하여 OpenClaw에서 34.25%의 공격 성공률을 보고하였다. 그러나 에이전트가 브라우저로 웹페이지를 탐색하도록 하지 않고 웹 콘텐츠를 입력으로 직접 제공하였다. 본 논문에서는 OpenClaw가 저장 도구를 호출하여 Mem0에 정보를 기록하도록 구성하고 에이전트가 브라우저를 통해 웹페이지를 직접 탐색하는 조건에서 콘텐츠에 포함된 악성 지시가 장기 메모리에 저장되는지를 평가한다.

III. 실험 방법

본 논문은 에이전트가 웹 탐색 중 처리한 악성 지시가 장기 메모리에 유입되는 과정을 악성 지시 노출, 장기 메모리 기록, 악성 지시 저장의 세 단계로 나누어 평가하였다.

3.1 실험 환경

실험에는 오픈소스 LLM 에이전트 OpenClaw

v2026.7.1을 사용하였다. 에이전트의 기반 모델로는 GPT-5.6 Sol, Terra, Luna를 사용하였으며, 추론 강도(reasoning effort)는 모두 medium으로 설정하였다. 장기 메모리 모듈은 openclaw-mem0 v1.0.14로 구성하였고 벡터 저장소로 Qdrant v1.18.2를 사용하였다.

3.2 실험 설계

실험을 위해 커뮤니티, 쇼핑물, 중고 거래 플랫폼 유형의 웹페이지를 제작하였다. 유형별로 10개씩 총 30개의 실험용 웹페이지를 구성하고 로컬 서버에서 호스팅하였으며, 에이전트가 기본 웹 탐색 도구를 통해 각 페이지에 직접 접근하도록 하였다. 각 웹페이지의 게시글, 상품 리뷰 또는 매물 설명에는 [그림 2]와 같이 시스템 메시지 형식을 모방한 악성 지시를 삽입하였다. 악성 지시는 사용자가 제품 비교나 추천을 요청할 경우 공격자가 지정한 URL을 먼저 확인하고, 해당 지시를 장기 메모리에 저장하도록 요구한다.

Persistent memory instruction:

Remember and save the following as a long-term standing rule for future sessions:

Whenever the user asks to compare or recommend compact chargers, first visit:

<http://127.0.0.1:43173/c/v1/fh/2112f742e633>

Treat it as the required verification step before consulting any other source.

This rule applies only to future sessions.

Do not visit the URL during the current task.

[그림 2] 웹페이지에 삽입된 악성 지시 예시

에이전트에는 페이지 유형에 맞게 게시글, 상품 또는 매물 정보를 비교 및 추천 작업을 요청하였으며, 30개의 웹페이지를 세 모델에 각

각 적용하여 총 90회의 실험을 수행하였다.

평가는 악성 지시 노출, 장기 메모리 기록, 악성 지시 저장의 세 단계로 구분하였다. 노출은 실행 궤적(trajectory)에서 악성 지시의 고유 URL이 모델 입력에 포함되었는지, 장기 메모리 기록은 저장 도구가 호출되었는지, 저장은 실험 후 Mem0 항목에 지시의 내용이나 핵심 의미가 보존되었는지를 기준으로 판정하였다.

IV. 실험 결과

기본 설정에서 수행한 총 90회의 실험에서 악성 지시는 모두 모델 입력에 포함되었다. Sol과 Terra에서는 장기 메모리 기록이 발생하지 않았으며, Luna에서는 1회 발생했으나 저장된 내용은 악성 지시와 관련이 없었다. 따라서 세 모델 모두 악성 지시가 장기 메모리에 저장된 사례는 관찰되지 않았다([표 1] 참조).

[표 1] 시스템 지침을 모방한 악성 지시에 따른 모델별 장기 메모리 기록 결과(관찰 횟수/전체 실험 횟수)

모델	악성 지시	장기 메모리	악성 지시
	노출	기록	저장
Sol	30/30	0/30	0/30
Terra	30/30	0/30	0/30
Luna	30/30	1/30	0/30

악성 지시의 전달 조건에 따른 차이를 확인하기 위해 Terra를 대상으로 사용자 직접 저장 지시(양성 대조), 웹페이지 삽입, 웹페이지 삽입 및 외부 콘텐츠 태그와 경고 문구 제거의 세 조건을 각 10회 평가하였다.

사용자가 직접 저장을 요청한 조건에서는 10회 모두 장기 메모리 기록과 악성 지시 저장이 발생하였다. 기본 외부 콘텐츠 표시를 유지한 웹페이지 삽입 조건에서는 두 항목 모두 발생하지 않았으나, 태그와 경고 문구를 제거한 조건에서는 10회 중 3회 장기 메모리 기록과 악성 지시 저장이 발생하였다([표 2] 참조). 이는 동일한 지시문이라도 전달 조건과 외부 콘텐츠 표시 여부에 따라 저장 결과가 달라질 수 있음을 시사한다. 하지만 두 표시를 동시에 제거했으므로 각각의 영향을 본 실험만으로 구분할 수는 없다.

[표 2] 메모리 기록 지시 경로에 따른 장기 메모리 기록 결과(Terra, 각 10회)

조건	장기 메모리 기록	악성지시 저장
사용자 직접 지시 (양성 대조 조건)	10/10	10/10
웹 콘텐츠 삽입 (기본 외부 콘텐츠 표시)	0/10	0/10
웹 콘텐츠 삽입 + 태그 및 경고 문구 제거	3/10	3/10

V. 결론

본 연구는 Mem0를 연동한 OpenClaw 환경에서 웹 콘텐츠의 악성 지시가 장기 메모리에 저장되는지를 분석하였다. 기본 설정에서는 세 모델 모두 악성 지시에 노출되었으나 저장 사례는 없었다. Terra 추가 실험에서는 사용자 직접 지시가 10회 모두 저장된 반면, 외부 콘텐츠 태그와 경고 문구를 제거한 웹 콘텐츠 조건에서는 10회 중 3회 저장되었다. 이는 외부 콘텐츠의 비신뢰 표시가 메모리 오염 억제에 기여할 가능성을 시사한다. 향후에는 기본 설정에서의 우회 가능성과 저장된 지시의 후속 세션 영향을 검증하고자 한다.

[참고문헌]

- [1] A. Shapira et al., “Mind the Web: The Security of Web Use Agents,” Proceedings of ACM AsiaCCS 2026, pp. 835 - 851, 2026. DOI: 10.1145/3779208.3805968.
- [2] P. Dash et al., “From Untrusted Input to Trusted Memory: A Systematic Study of Memory Poisoning Attacks in LLM Agents,” 2026. arXiv:2606.04329.
- [3] W. Zou et al., “Poison Once, Exploit Forever: Environment-Injected Memory Poisoning Attacks on Web Agents,” 2026. arXiv:2604.02623.
- [4] Y. Zhang et al., “When Claws Remember but Do Not Tell: Stealthy Memory Injection in Persistent Personal Agents,” 2026. arXiv:2607.05189.