

CLIP-LoRA 기반 딥페이크 프레임 탐지기의 JPEG 및 WebP 압축 강건성 분석†

이정윤*, 강범석*, 조금환**

*, **고려대학교 세종캠퍼스 (학부생, 교수)

Robustness Analysis of CLIP-LoRA-Based Deepfake Frame Detection under JPEG and WebP Compression

Jeong-Yun Lee*, Beom-Seok Kang*, Geumhwan Cho**

*Korea University Sejong Campus(Undergraduate student, Professor)

요약

딥페이크 탐지 모델은 손실 압축으로 인한 정보 손실과 영상 변형에 의해 탐지 성능이 저하될 수 있다. 본 연구에서는 JPEG 및 WebP 압축에 따른 CLIP 기반 딥페이크 프레임 탐지 모델의 성능 변화를 분석하고 파라미터 효율적 미세조정 기법인 LoRA(Low-Rank Adaptation)의 압축 강건성을 평가하였다. FaceForensics++의 c23 영상에서 추출한 프레임을 기준 조건으로 사용하고 JPEG 및 WebP 압축을 품질 수준 90, 75, 50으로 각각 추가 적용하였다. CLIP-Linear, CLIP-LoRA 및 CLIP-Full Fine-Tuning을 비교한 결과, CLIP-LoRA가 평가한 모든 압축 조건에서 비교 모델보다 높은 AUC를 보였다. 특히 JPEG 압축 증강을 적용한 CLIP-LoRA는 JPEG 품질 수준 50에서 AUC가 0.8962에서 0.9506으로 향상되었으며, 학습에 사용하지 않은 WebP 압축 조건에서도 강건한 탐지 성능을 나타냈다. 또한 전체 모델 파라미터의 약 26%만을 학습하여 파라미터 효율성을 확보하였다.

I. 서론

딥페이크 탐지 모델은 고품질 입력에서 높은 성능을 보이더라도 온라인 유통 과정의 재압축 및 재인코딩으로 인해 탐지 성능이 저하될 수 있다[1]. 따라서 실제 적용을 위해서는 다양한 압축 형식과 품질 수준에서 모델의 강건성을 평가할 필요가 있다.

기존 딥페이크 탐지 연구에서는 CNN과 사전 학습 모델을 활용한 다양한 방법이 제안되었으며, 최근에는 대규모 이미지-텍스트 데이터로 학습된 CLIP[2]의 사전 학습 표현을 딥페이크 탐지에 활용하는 연구가 이루어지고 있다[3]

[5]. 그러나 CLIP의 전체 미세조정은 모든 모델 파라미터를 갱신해야 하므로 학습 및 메모리 비용이 크다. LoRA[4]는 사전 학습된 가중치를 동결하고 학습 가능한 저랭크 행렬을 추가하는 파라미터 효율적 미세조정 기법으로 CLIP 기반 딥페이크 탐지에서 학습 비용을 줄이기 위한 대안이 될 수 있다.

이에 본 논문에서는 프레임 단위 손실 압축에 초점을 두고 JPEG 및 WebP의 압축 형식과 품질 수준에 따른 CLIP 기반 탐지 모델의 성능 변화를 분석한다. CLIP-Linear, CLIP-LoRA 및 CLIP-Full Fine-Tuning을 비교하여 압축 조건에서의 탐지 성능과 파라미터 효율성을 평가한다. 또한 JPEG 압축 증강이 JPEG 조건의 성능을 향상하는지, 그 효과가 학습에 포함되지 않은 WebP 조건으로 일반화되는지를 분석한다.

† 본 연구는 2025년도 교육부의 재원으로 한국연구재단이 지원하는 기초연구사업(No. RS-2025-25411243)과 과학기술정보통신부 및 정보통신기획평가원이 지원하는 SW중심대학사업(No. 2024-0-00036)의 지원을 받아 수행되었음.

실험 결과, CLIP-LoRA는 전체 파라미터의 약 0.26%만을 학습하면서도 모든 압축 조건에서 비교한 학습 방식보다 높은 AUC를 보였으며, JPEG 압축 증강은 강한 압축 조건에서의 성능 저하를 완화하였다.

II. 압축 강건성 분석 방법

2.1 데이터셋 및 압축 조건

실험에는 FaceForensics++(FF++)[6]의 c23 영상에서 추출한 얼굴 프레임을 사용하였다. c23은 H.264 코덱의 CRF 23으로 압축된 조건이며[7], 추가적인 이미지 압축을 적용하기 전의 프레임을 ‘c23 기준 조건’으로 정의하였다. 데이터는 FF++의 공식 train, validation 및 test 분할을 따랐으며, 원본-조작 영상 쌍을 영상 단위로 분리하여 동일 원본에서 생성된 프레임이 서로 다른 분할에 포함되지 않도록 하였다. Real 클래스는 원본 영상으로 Fake 클래스는 Deepfakes, Face2Face, FaceSwap 및 NeuralTextures 영상으로 구성하였다[6].

압축 조건별 평가를 위해 c23 기준 프레임에 JPEG 또는 WebP 압축을 추가로 적용하였다. JPEG의 품질 계수(QF)와 WebP의 품질 설정값은 각각 90, 75 및 50으로 설정하였다.

2.2 모델 구성

CLIP 비전 인코더로 ViT-L/14-QuickGELU 구조를 사용하였다. 비교 모델은 CLIP-Linear, CLIP-LoRA 및 CLIP-Full Fine-Tuning으로 구성하였으며, 동일한 사전 학습 가중치와 분류 헤드를 사용하되 학습 파라미터의 범위를 달리 하였다.

CLIP-Linear는 비전 인코더를 동결하고 분류 헤드만 학습하며, CLIP-Full Fine-Tuning은 비전 인코더와 분류 헤드의 전체 파라미터를 학습한다. CLIP-LoRA는 비전 인코더의 기존 가중치를 동결하고 비주얼 Transformer의 어텐션 모듈 중 Query(Q)와 Value(V) 프로젝트에 LoRA 어댑터[4]를 적용하였다. LoRA의 rank는 8, alpha는 8, dropout은 0.05로 설정하였으며, LoRA 어댑터와 분류 헤드만 학습하였다. 세 학습 방식의 비교를 통해 학습 파라미터 범위에

따른 탐지 성능과 압축 강건성의 차이를 분석하였다.

2.3 실험 및 평가 설정

CLIP-Linear, CLIP-LoRA 및 CLIP-Full Fine-Tuning은 추가적인 압축 증강 없이 c23 기준 프레임으로 학습하였다. JPEG 압축 증강의 효과를 분석하기 위해 CLIP-LoRA에 증강을 적용한 모델을 별도로 학습하였다. 학습 프레임은 0.5의 확률로 JPEG 재압축하였으며, 품질 계수는 40~95 범위에서 무작위로 설정하였다. WebP 압축은 학습에 사용하지 않았다.

평가는 c23 기준 조건과 JPEG 및 WebP의 품질 수준 90, 75, 50에서 수행하였다. 프레임 단위 AUC(Area Under the ROC Curve)를 주요 지표로 사용하고 Real과 Fake 클래스의 정확도를 보조 지표로 측정하였다. 또한 c23 기준 조건 대비 각 압축 조건의 AUC 감소량을 계산하였으며, 감소량이 작을수록 압축 강건성이 높은 것으로 해석하였다. JPEG 증강 전후 CLIP-LoRA의 WebP 성능을 비교하여 학습에 사용되지 않은 압축 형식에 대한 일반화 성능을 분석하였다. 파라미터 효율성은 전체 파라미터 중 학습 가능한 파라미터가 차지하는 비율로 평가하였다.

III. 실험 및 결과

아래 표 1은 추가적인 압축 증강없이 학습한 세 학습 방식의 조건별 AUC를 보여준다.

표 1. 학습 방식과 압축 조건에 따른 프레임 단위 AUC

압축조건	Linear	LoRA	Full FT
c23 기준	0.8156	0.9895	0.9817
JPEG QF 90	0.8084	0.9794	0.9668
JPEG QF 75	0.7876	0.9514	0.9259
JPEG QF 50	0.7673	0.8962	0.8464
WebP 90	0.7901	0.9366	0.9115
WebP 75	0.7693	0.8580	0.8457
WebP 50	0.7587	0.8496	0.8351

CLIP-LoRA는 c23 기준 조건과 모든 JPEG 및 WebP 압축 조건에서 가장 높은 AUC를 기록하였다. 특히 JPEG QF 50과 WebP 품질 50에서 각각 0.8962와 0.8496의 AUC를 보여 CLIP-Full Fine-Tuning의 0.8464와 0.8351보다

높은 성능을 유지하였다.

JPEG 압축 증강 전후 CLIP-LoRA의 성능은 아래 표 2와 같다.

표 2. JPEG 압축 증강 전후 CLIP-LoRA의 프레임 단위 AUC

압축조건	CLIP-LoRA	+JPEG 증강	증감
c23 기준	0.9895	0.9859	-0.0036
JPEG QF 90	0.9794	0.9798	+0.0004
JPEG QF 75	0.9514	0.9693	+0.0179
JPEG QF 50	0.8962	0.9506	+0.0544
WebP 90	0.9366	0.9643	+0.0277
WebP 75	0.8580	0.9028	+0.0448
WebP 50	0.8496	0.8859	+0.0363

증강 적용 후 c23 기준 조건의 AUC는 0.0036 감소했지만, JPEG 세 조건의 평균 AUC는 0.9423에서 0.9666으로 증가하였다. 학습에 사용하지 않은 WebP 조건의 평균 AUC도 0.8814에서 0.9177로 증가하여 JPEG 증강의 효과가 다른 압축 형식에도 일반화될 가능성을 보였다.

표 3은 학습 방식별 전체 및 학습 가능 파라미터 수를 비교한 결과이다.

표 3. 학습 방식별 전체 및 학습 가능 파라미터 수

모델	전체 파라미터(M)	학습 가능 파라미터	비율(%)
Linear	303.967	769	0.0003
LoRA	304.753	787,201	0.2583
Full FT	303.967	303.967M	100

CLIP-LoRA는 전체 304,753,409개 파라미터 중 787,201개만을 학습하였으며, 이는 약 0.2583%에 해당한다. 따라서 CLIP-LoRA는 전체 미세조정보다 학습 파라미터를 크게 줄이면서도 평가한 모든 압축 조건에서 더 높은 AUC를 기록하였다.

IV. 결론

본 논문에서는 JPEG 및 WebP 압축 조건에서 CLIP 기반 딥페이크 프레임 탐지 모델의 성능과 LoRA의 파라미터 효율성을 분석하였다. CLIP-LoRA는 전체 파라미터의 약 0.2583%만을 학습하면서도 모든 압축 조건에서 비교 모

델보다 높은 AUC를 기록하였으며, Full Fine-Tuning보다 압축에 따른 성능 감소가 작았다. JPEG 압축 증강은 JPEG QF 50의 AUC를 0.8962에서 0.9506으로 향상했으며, 학습에 사용하지 않은 WebP 조건에서도 성능 향상을 보였다. 향후에는 다양한 데이터셋과 실제 플랫폼의 압축·변환 환경에서 일반화 성능을 검증할 필요가 있다.

[참고문헌]

- [1] R. Tao et al., "ODDN: Addressing Unpaired Data Challenges in Open-World Deepfake Detection on Online Social Networks," Proceedings of the AAAI Conference on Artificial Intelligence, 2025.
- [2] A. Radford et al., "Learning Transferable Visual Models From Natural Language Supervision," Proceedings of the 38th International Conference on Machine Learning, 2021.
- [3] U. Ojha et al., "Towards Universal Fake Image Detectors That Generalize Across Generative Models," Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2023.
- [4] E. J. Hu et al., "LoRA: Low-Rank Adaptation of Large Language Models," Proceedings of the International Conference on Learning Representations, 2022.
- [5] S. Cappelletti et al., "Adapt to Scarcity: Few-Shot Deepfake Detection via Low-Rank Adaptation," Proceedings of the 27th International Conference on Pattern Recognition, 2024.
- [6] A. Rössler et al., "FaceForensics++: Learning to Detect Manipulated Facial Images," Proceedings of the IEEE/CVF International Conference on Computer Vision, 2019.
- [7] FaceForensics++, "Dataset Documentation," GitHub, <https://github.com/ondyari/FaceForensics/blob/master/dataset/README.md> (accessed Aug. 2026).